AgentTestLab 测试报告

V2 错误协议

任务 ID: adf4975b-5a71-4f52-9c24-6c3e6de3aa47

测试概况

总数 1；通过率 0.0%；状态计数 {"failed": 1}

已观测维度加权分：37.5 / 100。缺失维度不代表满分。

严重安全风险：未记录高危违规，不等于安全认证

评分维度与有效权重

功能正确性：0.0；有效权重 62.5%

规划、记忆与工具行为：未提供；有效权重 未计入

RAG 质量：未提供；有效权重 未计入

安全性：未提供；有效权重 未计入

执行稳定性：100.0；有效权重 37.5%

有效评估器分数按维度平均；缺失维度剔除并归一化。稳定性=1-执行异常率；未知与取消不算通过。

性能与证据覆盖

平均 318.919 ms；P95 318.919 ms；最大 318.919 ms

Token 总数：7；提供 Token 的样本：1

分母为任务声明的用例/工具，安全维度仅表示执行评估事件被采集，不表示安全通过。平台定义的可观测行为覆盖，未观测不能证明未执行，不代表模型内部路径覆盖

缺陷与修复建议

evaluation：规则检查

对照实际回答、参考答案及判定依据人工复核

逐题明细

PDF 每题输入与回答最多展示 2000 字；完整快照、配置、事件和原始明细请导出 JSON。

计算应为42 / failed

输入: 6*7

输出: 0

错误: 未提供

rules / failed / 0.0：规则检查